

Revisão Sistemática de Visão Computacional para Veículos Autônomos Agrícolas*

Renato Avila
Universidade Federal do ABC
Santo André, Brasil
renato.avila@ufabc.edu.br

Edson Kitani
FATEC
Santo André, Brasil
edson.kitani@fatec.sp.gov.br

Francisco de Assis Zampirolli
Universidade Federal do ABC
Santo André, Brasil
fzampirolli@ufabc.edu.br

Leopoldo Yoshioka
Universidade de São Paulo
São Paulo, Brasil
leopoldo.yoshioka@usp.br

Luiz Antonio
Celiberto Junior
Universidade Federal do ABC
Santo André, Brasil
luiz.celiberto@ufabc.edu.br

Ugo Ibusuki
Universidade Federal do ABC
Santo André, Brasil
ugo.ibusuki@ufabc.edu.br

Resumo—Com o aumento da demanda por eficiência na agricultura de precisão, a popularização do uso de veículos agrícolas autônomos (VAAs) é uma tendência crescente. A literatura sobre o assunto é vasta e se atualiza rapidamente. O objetivo deste trabalho é analisar o conhecimento produzido sobre VAAs para identificar as melhores técnicas e estratégias de visão computacional e redes neurais artificiais. Foi realizada uma revisão sistemática abrangendo os últimos 10 anos para identificar publicações científicas relevantes cuja implementação foi realizada em veículos agrícolas autônomos. Foram encontrados excelentes resultados em 35 artigos analisados. Dentre eles, as soluções que se utilizam de redes neurais convolucionais se destacam, sendo as mais populares nos últimos anos, e com abordagens variadas, como aprendizado por transferência e redes que fazem uso de concatenações de sensores.

Index Terms—Agricultura de precisão, Automação de Veículo Agrícola, Redes Neurais Convolucionais, Visão Computacional.

I. INTRODUÇÃO

Com o aumento da demanda por eficiência na agricultura de precisão, o uso de veículos agrícolas autônomos (VAAs) está se tornando tendência. No entanto, o aumento da utilização dessas máquinas também aumenta o risco de acidentes durante a operação. Para aumentar a segurança, vários sensores, incluindo diferentes tipos de câmeras, são utilizados em conjunto com algoritmos de visão computacional e aprendizado de máquina para detectar obstáculos, pessoas ou animais e auxiliar na tomada de decisões do veículo [1].

Este trabalho consiste em uma revisão sistemática da literatura sobre as técnicas e estratégias utilizadas em visão computacional para veículos autônomos agrícolas, apresentado como revisão bibliográfica. Na seção II, é explicada a metodologia utilizada na pesquisa e seleção dos artigos, incluindo pesquisas em bases de dados científicas, seleção de artigos por título, resumo e palavras-chave relevantes, bem como critérios de inclusão e exclusão rigorosos. Na seção III, são descritos os conceitos gerais de visão computacional, aprendizado de máquina, redes neurais artificiais e redes neurais convolucionais. Na seção IV, são descritos e analisados

os 35 artigos selecionados em termos de métodos, conjuntos de dados e resultados. Os resultados da seção V apontam que, nos últimos anos, as soluções mais comumente utilizadas foram aquelas baseadas em redes neurais convolucionais. Destaca-se, em particular, o uso frequente de técnicas de aprendizado por transferência e concatenação de diferentes sensores. Na seção VI, são apresentadas as conclusões deste trabalho, bem como as respostas às questões de pesquisa elaboradas para esta revisão sistemática.

II. METODOLOGIA

A revisão sistemática de literatura (RSL) adotou as diretrizes propostas por [2], as quais incluem questões de pesquisa, processo de busca, critérios de inclusão e exclusão, coleta e análise de dados, e avaliação da qualidade. A pergunta central que norteou a pesquisa foi:

Quais são as abordagens e aplicações que investigam o uso de visão computacional em veículos autônomos agrícolas?

Essa pergunta resume a motivação central do trabalho, mas também foram incluídas questões adicionais para abordar especificidades relevantes, como a reprodutibilidade do estudo, que serão apresentadas na última seção deste artigo.

A. Processo de busca

Para realizar essa RSL, foram utilizados como critérios de busca os artigos disponíveis nos sites Periódicos Capes (periodicos.capes.gov.br) e Google Scholar (scholar.google.com). Para conduzir a pesquisa, foram definidas *strings* de busca que fizeram uso dos recursos de filtragem disponibilizados pelos buscadores desses sites. As *strings* de busca foram definidas em inglês e incluíram termos como: ((“computer vision” OR “machine learning” OR “deep learning” OR “convolutional neural network”)) AND ((“agriculture” OR “agricultural”) AND (“vehicle” AND “autonomous”)).

Após a aplicação da *string* de busca definida, foram encontrados muitos artigos relacionados ao uso de drones e outros tipos de veículos autônomos que não eram relevantes para o objetivo desta revisão. Para excluir esses artigos, foram adicionadas as palavras “drone”, “UAV”, “aerial” e “underwater” à *string* de busca.

Pesquisa financiada pelo Governo Federal Brasileiro por meio da Fundação de Desenvolvimento da Pesquisa – Fundep Rota 2030/Linha V, N. 27192.02.01/2021.02.00.

B. Critérios de seleção

Os critérios de inclusão definidos para a seleção dos artigos foram os seguintes:

1) *Critério de inclusão CI1*: Os artigos devem relatar o uso de técnicas de visão computacional e redes neurais artificiais no contexto de utilização de veículos autônomos agrícolas.

2) *Critério de inclusão CI2*: Os artigos devem ter sido publicados nas seguintes bases: ScienceDirect [3], Scopus [4], Springer [5], Web of Science [6], ACM (Association for Computing Machinery) [7], MDPI (Multidisciplinary Digital Publishing Institute) [8] e a base da IEEE (Institute of Electrical and Electronic Engineers) [9].

3) *Critério de inclusão CI3*: O período de alcance para a escolha dos artigos ficou definido entre 2012 e 2022, totalizando pouco mais de dez anos.

4) *Critério de inclusão CI4*: A pesquisa considerou artigos escritos em inglês e português, desconsiderando capítulos de livros, anais e resumos de eventos e seminários.

C. Critério de exclusão

Para a seleção dos artigos, foi estabelecido o seguinte critério de exclusão:

Critério de exclusão CE1: Trabalhos cujo texto completo não esteja disponível para acesso gratuito na Web também foram desconsiderados.

D. Coleta e análise de dados

1) *Resultados da primeira busca*: Foram encontrados 1300 artigos na plataforma Google Scholar e 921 na Capes, totalizando 2221 artigos selecionados após atenderem aos critérios de inclusão CI3 e CI4, e serem excluídos aqueles que não atenderam ao critério CE1.

2) *Resultados da segunda busca*: Foram descartados os artigos que não atenderam ao critério de inclusão CI2 na etapa inicial da pesquisa, restando 464 artigos no Google Scholar e 832 no Periódicos Capes. No total, 1296 artigos foram selecionados nessa etapa.

3) *Resultados da terceira busca*: Os resultados das buscas no Google Scholar e Periódicos Capes foram unificados para criar uma base única e as duplicações foram removidas, resultando em 831 artigos que atenderam aos critérios de inclusão CI2, CI3 e CI4.

Em seguida, os resumos dos artigos foram analisados e os que não estavam relacionados com o tema objetivo deste trabalho e não preencheram os requisitos do CI1 foram descartados. Além disso, foram removidos os artigos que não possuíam acesso ao conteúdo completo (CE1).

Após essa análise, 782 artigos foram descartados por não atenderem ao critério de inclusão CI1, resultando em 49 artigos para leitura completa. Esses artigos foram distribuídos entre as bases ACM (4), IEEE (14), MPDI (16), ScienceDirect (12) e SpringerLink (3).

E. Avaliação da qualidade

O critério de inclusão CI2 está relacionado com a qualidade das publicações selecionadas. Além disso, foi avaliado se o método é reproduzível, ou seja, se o *dataset* e o código estão disponíveis para reprodução.

III. FUNDAMENTOS

Nesta seção, apresentaremos uma introdução aos fundamentos teóricos que sustentam o desenvolvimento deste trabalho. Abordaremos o Processamento de Imagens, que busca desenvolver algoritmos para manipular e transformar imagens digitais, a fim de melhorar sua qualidade, extrair informações relevantes ou corrigir distorções. Além disso, falaremos sobre a Visão Computacional, área da inteligência artificial que desenvolve algoritmos para permitir que as máquinas interpretem imagens e vídeos, incluindo tarefas como reconhecimento de objetos, segmentação de imagens e detecção de movimento.

De acordo com Gonzalez e Woods [10], não há um consenso entre os autores sobre quando o processamento de imagens termina e outras áreas relacionadas, como análise de imagens e visão computacional, começam. Neste artigo, consideramos como abuso de terminologia a inclusão de trabalhos que utilizam apenas o processamento de imagens para segmentar objetos em imagens na área de Visão Computacional, embora saibamos que essa área se sobrepõe a outras, como veremos a seguir.

A Aprendizagem de Máquina é uma técnica de inteligência artificial que possibilita que as máquinas aprendam com dados, sem a necessidade de programação explícita. Esse processo envolve identificar padrões nos dados e criar modelos matemáticos para previsões ou classificações.

As Redes Neurais Artificiais são modelos matemáticos inspirados no funcionamento do cérebro humano e são amplamente utilizadas em Aprendizagem de Máquina. A seguir, apresentaremos as Redes Neurais Convolucionais (CNN do inglês *Convolutional Neural network*), que são um tipo especial de Rede Neural amplamente utilizada em tarefas de Visão Computacional. Por fim, apresentaremos alguns Trabalhos Relacionados que serviram como referência para o desenvolvimento deste estudo.

A. Visão Computacional

A Visão Computacional procura fornecer aos computadores a capacidade de interpretar informações visuais do mundo ao nosso redor [11]. As aplicações desenvolvidas nessa área, incluindo reconhecimento facial, detecção de objetos, veículos autônomos, imagens médicas e realidade aumentada, têm o potencial de melhorar diversos aspectos de nossas vidas, desde saúde até transporte e entretenimento. No entanto, a complexidade e variabilidade dos dados visuais, como condições de iluminação, escala, orientação e contexto, apresentam um dos principais desafios da Visão Computacional, tornando difícil a interpretação precisa das informações visuais pelos computadores. Técnicas como aprendizado profundo, redes neurais convolucionais e extração de características permitem que os computadores aprendam a partir de grandes conjuntos de dados de imagens rotuladas e extraíam informações significativas dos dados visuais.

B. Aprendizado de Máquina

O Aprendizado de Máquina é uma subárea da inteligência artificial que utiliza algoritmos e modelos estatísticos para permitir que sistemas de computador aprendam e melhorem com a experiência [12]. As aplicações são diversas, como previsão de comportamento do cliente, diagnóstico médico e

detecção de atividades fraudulentas, melhorando aspectos de nossas vidas, como saúde, finanças e segurança cibernética. Uma das principais vantagens do aprendizado de máquina é a capacidade de processar uma quantidade relevante de dados com rapidez e precisão, identificando padrões e percepções difíceis de serem detectados pelos humanos. As técnicas incluem aprendizado supervisionado, não supervisionado e por reforço, permitindo que os computadores aprendam a partir de dados rotulados ou não rotulados para fazer previsões ou ações baseadas no aprendizado.

C. Rede Neural

Redes neurais artificiais são modelos empregados em aprendizado de máquina inspirados na estrutura e função do cérebro humano, com ampla aplicação em reconhecimento de imagem, processamento de linguagem natural e robótica. O objetivo dessas redes é aprender com exemplos e usá-los para fazer previsões ou ações baseadas em novos dados. Elas processam e analisam dados complexos, identificando padrões e relacionamentos difíceis de serem detectados pelos humanos. As técnicas incluem redes *feedforward*, recorrentes e convolucionais, adaptadas para processar diferentes tipos de dados, como imagens, fala e texto.

D. Rede Neural Convolucional

As Redes Neurais Convolucionais (CNNs) são modelos empregados em aprendizado profundo projetados para extrair automaticamente características de imagens e vídeos [13]. Elas têm diversas aplicações, como classificação de imagens, detecção de objetos e segmentação. Uma das principais vantagens das CNNs é sua capacidade de processar uma quantidade relevante de dados visuais com rapidez e precisão, usando camadas convolucionais para identificar características de baixo nível e combiná-las em características de nível superior. Isso permite a identificação de objetos e cenas complexas em imagens e vídeos. Para otimizar o desempenho da rede, técnicas como *pooling* e camadas totalmente conectadas são utilizadas, bem como o aumento de dados para melhorar a capacidade de generalização e evitar o *overfitting*.

E. Veículos Autônomos Agrícolas

Veículos agrícolas autônomos são máquinas avançadas projetadas para realizar diversas tarefas sem intervenção humana. Esses veículos utilizam tecnologias de ponta, como inteligência artificial, sensores e GPS para navegar, operar e executar operações agrícolas de forma autônoma. Em seu trabalho [14] destaca que a navegação baseada na visão desempenha um papel crucial ao permitir que os veículos agrícolas autônomos interpretem informações visuais no seu entorno. Sensores de visão, como câmeras, captam informações visuais em tempo real sobre o campo, as culturas e os obstáculos. Ao empregar técnicas e algoritmos avançados de processamento de imagem, os veículos autônomos podem extrair dados significativos das imagens capturadas. A utilização de veículos agrícolas autônomos oferece vários benefícios aos agricultores e à indústria agrícola na totalidade. Aumenta a eficiência operacional otimizando tarefas, reduzindo a necessidade de mão de obra e aumentando a produtividade. Além disso, os veículos autônomos melhoram a segurança,

minimizando a exposição humana a condições potencialmente perigosas.

F. Trabalhos relacionados

Devido à importância do tema, várias revisões foram produzidos visando analisar o tema. Em seu trabalho, [1] identificam a aplicabilidade do uso de visão computacional na agricultura de precisão para os cinco principais grãos cultivados no mundo: milho, arroz, trigo, soja e cevada. São apresentados nesta revisão sistemática 25 trabalhos que foram selecionados e apresentam diferentes estratégias para tratar aspectos relacionados à detecção de doenças, qualidade e fenotipagem. Dentre as oportunidades identificadas pela revisão, pode-se citar o uso de GPUs e técnicas avançadas de inteligência artificial, como DBN (Deep Belief Networks) na construção de métodos robustos de visão computacional aplicados à agricultura de precisão. Em seu artigo, [14] fornece uma visão geral dos desafios associados à navegação de precisão de robôs e veículos agrícolas em ambientes agrícolas complexos. Ele enfatiza o potencial da tecnologia de visão computacional como uma ferramenta promissora para uma navegação precisa e em tempo real. Segundo os autores, o baixo custo do hardware e a riqueza de informações visuais oferecidas pela visão computacional levaram a extensas pesquisas e ampla adoção na navegação autônoma para robôs agrícolas. O artigo de [15] foca nas tendências de desenvolvimento e nas perspectivas futuras de veículos elétricos *off-road* e robôs agrícolas baseados em energia renovável. Destaca os desafios enfrentados pelo setor agrícola, tais como o crescimento populacional, a procura de energia, a escassez de mão-de-obra e o aquecimento global. Discute o desenvolvimento de veículos elétricos, combustíveis verdes alternativos e tecnologias energeticamente eficientes, como veículos híbridos elétricos, robóticos e autônomos, que melhoram a qualidade do trabalho e o conforto do operador. Além disso, explora tecnologias digitais, como a comunicação em rede avançada, a inteligência artificial e a cadeia de blocos, que desempenham um papel na resposta aos desafios e oportunidades da indústria e da investigação no setor agrícola. Em sua revisão, [16] avalia a literatura existente e as contribuições históricas da pesquisa relacionadas ao projeto e prototipagem de veículos terrestres agrícolas autônomos. A motivação desta revisão é divulgar as principais características do BOPS-1960, um trator autônomo conceituado na década de 1960 na Universidade Alma Mater Studiorum de Bolonha (UNIBO). Além disso, o estudo avalia as principais características do moderno veículo terrestre não tripulado (UGV) DEDALO projetado para operações em pomares e vinhedos. O estudo fornece uma descrição detalhada dos princípios fundamentais, tecnologia e sensores empregados em ambos os protótipos UNIBO. Também inclui uma análise dos UGV desenvolvidos para a agricultura nos últimos anos por centros de pesquisa em todo o mundo.

IV. TRABALHOS SELECIONADOS

Após a conclusão de todas as etapas de seleção descritas na seção II, foram selecionados 49 artigos para leitura detalhada e análise de conteúdo. Após a leitura desses artigos, 14 foram excluídos, totalizando 35 artigos que serão apresentados de forma resumida na próxima seção. A exclusão foi necessária,

pois alguns artigos eram estudos do tipo *survey*, outros descreviam apenas conjuntos de dados e, principalmente, não abordavam a parte de visão computacional. Os artigos selecionados foram agrupados conforme o algoritmo principal utilizado ou a área de pesquisa, conforme listado abaixo:

A. Visão Computacional

Os trabalhos citados abaixo apresentam técnicas de visão computacional aplicadas em veículos autônomos agrícolas. Em seu artigo, [17] propõe um método para guiar robôs em plantações de milho usando visão computacional e controle baseado em lógica difusa. Já [18] utiliza a Transformada de *Hough* para identificar o caminho de navegação em ambientes onde existe a ocorrência de plantas daninhas, com eficácia comprovada em testes experimentais. A Transformada *Hough* é uma técnica de processamento de imagem amplamente utilizada em visão computacional, robótica, detecção de objetos e reconhecimento de padrões [19].

O método descrito em [20] rastreia a direção e o deslocamento lateral das linhas de cultivo, dispensando o uso de segmentação binária e sendo aplicável a campos com uma ampla variedade de aparências. Para isso, o sistema de percepção utiliza a biblioteca OpenCV [21]. Em [22], um trator segue um plano de *waypoints* baseados em coordenadas *Global Positioning System* (GPS), mas usa um sistema de detecção de linhas de cultivo para corrigir incertezas na posição dos pontos e detectar a presença de ervas daninhas. O algoritmo proposto em [23] superou o método padrão de transformada *Hough* em termos de taxa e precisão de detecção de linhas de plantio em campos agrícolas e foi combinado com outros dois algoritmos para melhorar seu desempenho em distâncias curtas.

Para detecção de pedestres, o artigo [24] apresenta um sistema que utiliza uma câmera frontal posicionada em um trator, com boa precisão em distâncias de 8 a 20 metros e melhorado com a combinação de outros algoritmos em distâncias mais curtas. Ainda em técnicas de detecção, [25] propõe uma estratégia de análise espaço-temporal para detecção de obstáculos estáticos e dinâmicos em ambientes agrícolas, sem a necessidade de treinamento prévio. O protótipo de robô agrícola autônomo descrito em [26] é equipado com sensores e utiliza GPS e sistema de visão para gerar mapas de posição, projetado para semear sementes em intervalos predeterminados no campo. Estes trabalhos fazem uso do MATLAB [27] para o processamento de imagens.

O artigo [28] apresenta uma solução baseada em visão de máquina para a navegação autônoma de um veículo utilitário agrícola, com resultados bem-sucedidos em testes de laboratório e campo, com potencial para guiar pequenos veículos utilitários no pomar. Para isso, faz uso do NI LabVIEW (*National Instruments Laboratory Virtual Instrument Engineering Workbench*) [29]. O artigo [30] apresenta um sistema de rastreamento de trajetória para tratores com câmeras de visão binocular, com alta precisão de controle e estabilidade em experimentos em campo de algodão. Faz uso da transformada *Census*, uma técnica de processamento de imagens usada para comparação e identificação de disparidades. Já o artigo [31] descreve um sistema *retrofit* de visão de máquina para tratores usados, com alto desempenho na discriminação de plantas daninhas em testes de campo em cultivos de alface

e brócolis. Foi utilizado MATLAB no processamento das imagens. O artigo [32] apresenta um sistema de detecção de obstáculos baseado em visão computacional, com o uso de câmeras infravermelhas e a biblioteca *OpenCV* para identificar obstáculos em várias etapas.

O artigo [33] propõe um conjunto de algoritmos de visão computacional para localizar veículos no campo com alta precisão, que supera os métodos tradicionais de RTK-GPS em termos de custo, complexidade e confiabilidade. RTK-GPS (*Real-Time Kinematic Global Positioning System*) é um sistema de posicionamento por satélite que fornece informações de localização em tempo real com alta precisão. Em seu trabalho [34], propõe um sistema escalável, modular e flexível de mapeamento e navegação no solo para sistemas agrícolas autônomos, usando tecnologia de visão computacional e IoT, que é uma rede de dispositivos interconectados que são capazes de coletar e transmitir dados sem a necessidade de interação humana direta. Neste trabalho é utilizado ORB-SLAM2, um sistema de localização e mapeamento simultâneo (SLAM) baseado em visão, que utiliza a técnica de recursos visuais de *Oriented FAST and Rotated BRIEF* (ORB) para detectar e descrever características em imagens. Os dados gerados são utilizados para construir um mapa do ambiente. Em seu artigo, [35] apresenta um método de segmentação para construção de mapas de obstáculos no solo usando LIDARs (*Light Detection and Ranging*), que são dispositivos que utilizam lasers para medir distâncias e criar mapas tridimensionais do ambiente, para condução automatizada na agricultura em chassi robótico, com foco na eficiência computacional para computadores de bordo com recursos limitados.

Por fim, o artigo [36] propõe uma técnica para navegação em pomares usando um robô agrícola utilizando técnicas como *Color Index of Vegetation Extraction* (CIVE), *Principal Component Analysis* (PCA) e *Maximum Average Accuracy* (MAA) para processamento das imagens, filtros *Gabor* para detectar padrões e *K-means clustering* para agrupamento por característica. Enquanto o artigo [37] apresenta um sistema para navegar em campos de cultivo sob as copas das árvores.

B. Aprendizado de Máquina

Os artigos apresentados abaixo utilizam técnicas de Aprendizado de Máquinas em conjunto com visão computacional para auxiliar a navegação de veículos agrícolas. O artigo [38] apresenta uma estrutura de autoaprendizagem para veículos autônomos agrícolas que utiliza um sistema de visão 3D para reconhecer o ambiente e obstáculos. Utiliza *Expectation-Maximization* (EM), *Bayesian Information Criterion* (BIC) e distância de *Mahalanobis* no processo. Já o artigo [39] apresenta um método de Detecção Visual de Obstáculos baseado em Novidades, enquanto [40] apresenta um sistema de classificação de plantas que faz uso do *Random Forest*, um classificador baseado em árvores de decisão [41] e *Markov Random Fields* [42]. O artigo [43] descreve um método para localização das linhas de cultivo fazendo uso de *Support Vector Machines* (SVMs) [44], enquanto [45] apresenta um sistema que combina diferentes técnicas de visão computacional para ajudar veículos autônomos a navegar em ambientes agrícolas, utilizando *Simultaneous Localization and Mapping*

(SLAM) e algoritmos *Multi-View Stereo* (MVS) para criar mapas 3D detalhados do ambiente.

C. Rede Neural

A partir desta subseção, são apresentados artigos que utilizam redes neurais artificiais como parte principal de suas soluções. Em [46], é apresentado um algoritmo de detecção de objetos em tempo real para robótica autônoma na agricultura, que utiliza redes neurais artificiais. O algoritmo de máquina de aprendizado extremo de características de cores multi-especialista (MEC-ELM) foi desenvolvido pelos pesquisadores, utilizando uma abordagem em cascata para a detecção de objetos em imagens. Ele usa uma tabela de área somada (SAT) para extrair características de cor e uma rede neural de aprendizado extremo (ELM) para classificar objetos. O algoritmo alcançou 84% de precisão e 91% de revocação na detecção de ervas daninhas em imagens de baixa resolução em apenas 0,5 segundos por quadro. Para superar as limitações de resolução, os pesquisadores propuseram uma variante do MEC-ELM que usa uma matriz de co-ocorrência ao nível de cor (CLCM) e análise de textura, alcançando entre 78-85% de precisão e 81-93% de revocação na detecção das classes gado, ervas daninhas e quadriciclos em tempos entre 1 e 2 segundos por quadro.

D. Rede Neural Convolutiva

Os artigos desta seção utilizam principalmente Redes Neurais Convolucionais (CNNs) em suas soluções. O trabalho [47] utiliza uma CNN profunda para detectar obstáculos conforme a norma ISO/DIS 18497 em culturas agrícolas. O artigo [48] descreve o DeepAnomaly, um algoritmo baseado em CNNs que utiliza detecção de anomalias para identificar obstáculos em veículos autônomos com alto desempenho e tempo de processamento mais rápido que outros métodos. Já o trabalho [49] apresenta o DaSNet, uma arquitetura inspirada em LSTM e GRU que utiliza CNNs para realizar detecção e segmentação em tempo real de maçãs e galhos em pomares.

O trabalho [50] explora o uso de diferentes modelos de redes neurais de aprendizado profundo, incluindo *ssd-Mobilenet v1* e *v2*, *pednet*, *multyped* e *ssd-inception v2*, em sistemas embarcados NVIDIA Jetson para detecção de objetos em áreas rurais complexas. O Jetson Nano foi selecionado como unidade de processamento gráfico integrado e o artigo conclui que o modelo *pednet* é eficaz na detecção de pedestres, enquanto os modelos *ssd-mobilenet v2* e *ssd-inception v2* são melhores na detecção de outros objetos em cenários complexos. Fazendo uso de vários modelos simultaneamente, é possível melhorar a precisão e o tempo de processamento.

O artigo [51] apresenta a rede *SegNet*, que utiliza aprendizado por transferência e uma topologia baseada nas primeiras 13 camadas convolucionais da rede VGG 16 para a segmentação semântica de imagens em cinco classes: vegetação, grama, terra, campo de colheita e obstáculo. O artigo [52] é uma continuação do trabalho anterior [49], e apresenta um método para colheita robótica de maçãs utilizando aprendizado profundo para detecção e segmentação de frutas, combinado com o uso de *PointNet* [53] para estimar a pose adequada para cada fruta antes de ser colhida. O artigo

[54] propõe um algoritmo de navegação baseado em visão computacional e aprendizado profundo para robôs agrícolas, utilizando uma rede convolutiva em cascata e um método híbrido de fusão de convolução dilatada para processar imagens, e um algoritmo aprimorado de transformada de *Hough* para extrair a rota navegável.

Em seu artigo, [55] apresenta uma solução para robôs móveis em tarefas agrícolas, utilizando câmeras RGB-D para navegar em ambientes externos desafiadores com obstáculos dinâmicos e estáticos. O método proposto consiste em obter uma imagem RGB e uma imagem de profundidade, realizar a segmentação semântica e construir a nuvem de pontos projetados na grade 2D utilizada pelo algoritmo de navegação. Já o artigo [56] apresenta um sistema em três unidades para operações agrícolas autônomas, incluindo um *drone* para definir a rota do veículo terrestre, uma unidade de controle remoto e um *agrobot* autônomo multifuncional. Neste trabalho foi utilizado *Robot Operating System* (ROS) [57]. Já em [58], os autores propõem um sistema de estimativa de rendimento de colheita que utiliza apenas uma câmera monocular e uma quantidade limitada de informações de supervisão. O sistema detecta, localiza e mapeia frutas e copas das árvores para estimar o rendimento total da colheita, e pode ser utilizado com câmeras portáteis ou robôs autônomos, reduzindo o tempo de implantação, o consumo de energia e o custo geral. O método proposto é comparável aos métodos baseados em visão totalmente supervisionados e aos sistemas tradicionais que dependem de sensores mais caros e que exigem mais energia.

Uma estrutura utilizando visão computacional para coletar e extrair informações de culturas e fenológicas de imagens adquiridas no nível da rua, utilizando câmeras baratas e aprendizado profundo é apresentada no artigo [59]. A classificação foi feita utilizando um modelo de reconhecimento de imagem baseado em aprendizado por transferência com a rede neural convolutiva *MobileNet*, e uma metodologia de *hypertuning* foi desenvolvida para obter o modelo de melhor desempenho. O melhor modelo classificou o tipo de cultura com uma pontuação Macro F1 de 88,1% e o estágio fenológico em 86,9%.

Por fim, em [60], os autores propõem o uso de *autoencoders* convolucionais para detecção de objetos que oferecem risco de colisão para veículos agrícolas autônomos, uma vez que algoritmos baseados em visão apresentam limitações na detecção de classes desconhecidas de objetos. *Autoencoders* convolucionais são uma variação das redes neurais *autoencoders*, e são usados para comprimir imagens em um espaço latente de representações de baixa dimensão. Isso permite que sejam usados para tarefas de redução de dimensionalidade, onde a representação de dados é reduzida para uma dimensão menor sem perda significativa de informações. Foram comparados diferentes tipos de *autoencoders* e um detector de objetos de última geração, e os *autoencoders* foram capazes de detectar objetos desconhecidos, enquanto o detector de objetos falhou em identificar classes conhecidas de objetos em casos específicos.

V. RESULTADOS E DISCUSSÕES

A Tabela I apresenta uma compilação dos artigos analisados na seção anterior, organizados por área e ano de

Tabela I
ARTIGOS AVALIADOS. AS SIGLAS ESTÃO EXPLICADAS NA SEÇÃO IV.

artigo	área	ano	base	sensores	biblioteca/arquitetura	solução	citações
[17]	VC	2012	ELSEVIER	câmera	MATLAB	navegação (trajeto)	191
[18]	VC	2014	SPRINGER	câmera	transformada Hough	navegação (trajeto)	8
[20]	VC	2014	IEEE	câmera + imu	OpenCV	navegação (trajeto)	106
[22]	VC	2014	MDPI	câmera + gps + imu	NI LabView	navegação e detecção	59
[23]	VC	2015	ELSEVIER	câmera	MATLAB	navegação (trajeto)	100
[24]	VC	2016	ELSEVIER	câmera	MATLAB	segmentação e detecção	17
[25]	VC	2016	ELSEVIER	ccd filtro Bayer GR	MATLAB	segmentação e detecção	36
[26]	VC	2017	IEEE	câmera + outros	MATLAB	navegação (mapa)	51
[28]	VC	2018	ELSEVIER	câmera	LabView (NI)	navegação (trajeto)	95
[30]	VC	2018	ELSEVIER	câmera binocular	transformada Census	navegação (trajeto)	46
[31]	VC	2018	MDPI	câmera	MATLAB	detecção	20
[32]	VC	2019	ACM	câmera binocular IR	OpenCV	detecção	1
[33]	VC	2020	IEEE	câmeras + LIDAR	código próprio	navegação (trajeto)	15
[34]	VC	2020	IEEE	câmera	ORB-SLAM2	navegação (mapa)	38
[35]	VC	2020	IEEE	câmera	OpenCV	detecção	1
[36]	VC	2021	ELSEVIER	câmera + outros	filtro Gabor e K-means	navegação (trajeto)	23
[37]	VC	2021	ELSEVIER	câmera ToF	código próprio	navegação (trajeto)	29
[38]	AM	2012	MDPI	câmera estéreo	código próprio	classificação	74
[39]	AM	2014	IEEE	câm. estéreo + scanner laser	ROS	detecção	31
[40]	AM	2014	IEEE	câmera multispectral	código próprio	classificação	167
[43]	AM	2015	IEEE	câmera estéreo	OpenCV SVM	navegação (trajeto)	22
[45]	AM	2021	IEEE	câmera	OpenVSLAM	navegação (mapa)	16
[46]	RN	2018	ELSEVIER	câmera	algoritmo MEC-ELM	detecção e classificação	26
[47]	CNN	2016	MDPI	câmeras	AlexNet + TL	detecção e classificação	72
[48]	CNN	2016	MDPI	câmera estéreo + outros	MATLAB + CNN modificada	detecção	145
[49]	CNN	2019	MDPI	kinect-v2	DaSNet (Deep CNN)	segmentação e detecção	82
[50]	CNN	2020	MDPI	câmera	TensorRT	detecção e classificação	64
[51]	CNN	2020	IEEE	câmera	SegNet	segmentação	1
[52]	CNN	2020	MDPI	câmera RGB-D	mobile-DaSNet + TL	segmentação e detecção	77
[54]	CNN	2021	SPRINGER	ccd	ResNet101	navegação (trajeto)	14
[55]	CNN	2021	MDPI	câmera RGB-D	DeepLabV3+	navegação (obstáculos)	25
[56]	CNN	2021	MDPI	câm. 3D, NIR, térmica	CNNs	segmentação e detecção	25
[58]	CNN	2022	ELSEVIER	câmera	ResNet50 + TL	estimativas de produção	7
[59]	CNN	2022	ELSEVIER	câmera	tensorflow MobileNet	classificação	8
[60]	CNN	2022	MDPI	câmera	Autoencoders VGG19	detecção	5

publicação. Em alguns artigos, mais de uma área é utilizada, como Visão Computacional (VC) e Aprendizado de Máquina (AM), mas consideramos apenas a área mais relevante para a obtenção dos resultados apresentados no artigo. Geralmente, Visão Computacional é utilizada apenas para pré-processamento, portanto, não é a área mais relevante. As outras áreas incluem CNN e Redes Neurais Artificiais (RNA). É importante destacar que apenas o artigo [58] disponibilizou um conjunto de dados próprio para a realização dos experimentos. O pseudo-código é disponibilizado no corpo dos artigos de [25] e [34]. Os artigos restantes não disponibilizaram o código utilizado nos experimentos ou suas bases, o que pode dificultar a replicação dos resultados. A contagem de citações na última coluna foi obtida pelo *Google Scholar* em 29 de abril de 2023.

Ao analisar a Tabela I, é possível observar que os artigos mais recentes sobre o tema estão relacionados às redes neurais convolucionais (CNNs), que aparentemente apresentam os melhores resultados. Alguns autores desenvolveram suas próprias CNNs, baseadas em redes bem documentadas na literatura, também foi observada a utilização de aprendizado por transferência (TL do inglês *Transfer Learning*) para a criação de soluções. No entanto, devido à falta de disponibilidade dos conjuntos de dados e códigos utilizados na maioria dos artigos, não é possível comprovar completamente esses resultados. Portanto, é fundamental que os autores compartilhem seus dados e códigos com a comunidade científica, a fim de permitir a replicação e validação dos

resultados obtidos.

VI. CONCLUSÕES

Este trabalho permitiu identificar os avanços mais promissores em técnicas de visão computacional e redes neurais artificiais para veículos agrícolas autônomos. Segundo os resultados desta revisão sistemática, as soluções baseadas em redes neurais convolucionais são as mais utilizadas atualmente, em especial aquelas que fazem uso de aprendizado por transferência ou a concatenação de diferentes sensores.

Estas abordagens podem ser adotadas por pesquisadores e desenvolvedores interessados em aumentar a autonomia e precisão dos veículos agrícolas. Com o contínuo progresso da visão computacional e do aprendizado de máquina, é provável que veículos agrícolas totalmente autônomos se tornem uma realidade em breve, aumentando a eficiência e sustentabilidade da agricultura de precisão.

Assim, este artigo fornece diretrizes importantes para o desenvolvimento de tecnologias essenciais à revolução da automação agrícola. Ao adotarem as melhores práticas identificadas, os engenheiros podem dar um grande salto em direção a sistemas agrícolas mais inteligentes, produtivos e eco eficazes.

Respostas às questões de pesquisa

- Quais *dataset* foram utilizados? São de livre acesso?
Resposta: A maioria dos autores criou a base de dados utilizada na criação da solução e não as disponibilizaram

publicamente. O mesmo pode ser dito dos códigos produzidos. Alguns artigos utilizaram bases de imagens rotuladas públicas, como o ImageNet [61], Pascal VOC [62] e COCO [63];

- Quais técnicas de redes neurais artificiais foram utilizadas?

Resposta: As técnicas mais utilizadas recentemente são a CNN com aprendizado por transferência;

- Quais são as principais motivações para o uso de visão computacional em veículos autônomos agrícolas? Em outras palavras, qual é a principal função ou característica do sistema gerado?

Resposta: A maioria dos trabalhos busca aprimorar os sistemas de navegação e orientação dos veículos autônomos, resultando em mapas e linhas de trajeto mais precisos. A segurança das operações é uma preocupação recorrente e, por isso, foram desenvolvidos sistemas de detecção de objetos e pedestres, além de mapas de obstáculos. Alguns trabalhos se concentram na detecção e classificação de produtos agrícolas para colheita ou estimativas de produção, tornando a detecção e classificação a principal característica do sistema gerado;

- Quais são os tipos de câmeras mais utilizados?

Resposta: A maioria dos trabalhos utilizou câmeras monoculares RGB de baixo custo. Alguns autores enfatizaram o uso deste tipo de câmera. Um pequeno número de trabalhos (3) utilizou câmeras binoculares ou sistemas de visão estéreo com mais de uma câmera. Além disso, foram utilizadas câmeras de profundidade, RGB-D e *Time-of-Flight* (ToF). Um único artigo usou uma combinação de câmera térmica e *Near-Infrared* (NIR). Dentre outros sensores utilizados nos artigos, estão LIDARs, sistemas de posicionamento global (GPS), unidades de medição inercial (IMU), infravermelho (IR), radar e ultrassom;

- Quais recursos (linguagens, ferramentas, bibliotecas e arquiteturas de redes) foram utilizadas no desenvolvimento das soluções?

Resposta: Os recursos mais citados para processamento de imagens foram OpenCV [21], MATLAB [27] e *National Instruments LabView* [29]. Em relação às CNNs utilizadas como base para a criação de novas arquiteturas, os nomes mais recorrentes foram: AlexNet, ResNet, VGG, MobileNet, Faster R-CNN e YOLO.

Trabalhos Futuros

Considerando as perspectivas promissoras nesta área de pesquisa, pretendemos produzir uma versão expandida deste artigo, incorporando melhorias que ampliem o entendimento do estado atual neste campo. Pretendemos organizar as informações de forma mais clara e acessível, adotando um novo formato que facilite a compreensão dos leitores. Uma abordagem promissora é dividir os trabalhos por tipo de cultura, destacando os contextos específicos de uso dos veículos agrícolas autônomos. Isso permitirá uma análise aprofundada das particularidades de cada cultura, explorando soluções e avanços relevantes para cada contexto agrícola. Também incluiremos uma discussão mais detalhada sobre a tendência de utilização de redes neurais artificiais, que

são ferramentas poderosas no processamento de dados na agricultura. Com essas melhorias, nosso artigo preencherá lacunas no conhecimento atual e explorará as possibilidades de pesquisa nesse campo em constante evolução.

Agradecimentos

Os autores gostariam de agradecer a toda equipe do projeto (Fundep Rota 2030/Linha V, N. 27192.02.01/2021.02.00).

REFERÊNCIAS

- [1] Diego Inácio Patrício and Rafael Rieder. Computer vision and artificial intelligence in precision agriculture for grain crops: A systematic review. *Computers and electronics in agriculture*, 153:69–81, 2018.
- [2] Maria Cristiane Barbosa Galvão and Ivan Luiz Marques Ricarte. Revisão sistemática da literatura: conceituação, produção e publicação. *Logeion: Filosofia da informação*, 6(1):57–73, 2019.
- [3] ScienceDirect. Science Direct. <https://www.sciencedirect.com/>, 2022. Online; Acessado em 12 de julho de 2022.
- [4] Scopus. Scopus Review. <https://www.scopus.com/>, 2022. Online; Acessado em 12 de julho de 2022.
- [5] SpringerLink. Springer Link. <https://link.springer.com/>, 2022. Online; Acessado em 12 de julho de 2022.
- [6] Web of Science. Web of Science. <https://www.webofknowledge.com/>, 2022. Online; Acessado em 12 de julho de 2022.
- [7] ACM Digital Library. ACM Digital Library. <https://dl.acm.org/>, 2022. Online; Acessado em 12 de julho de 2022.
- [8] MDPI. Multidisciplinary Digital Publishing Institute. <https://www.mdpi.com/>, 2022. Online; Acessado em 12 de julho de 2022.
- [9] IEEE Xplore Digital Library. IEEE Xplore Digital Library. <https://ieeexplore.ieee.org/Xplore/home.jsp>, 2022. Online; Acessado em 12 de julho de 2022.
- [10] Rafael C Gonzalez and Richard C Woods. *Processamento digital de imagens*. Pearson Educación, 2009.
- [11] Richard Szeliski. *Computer vision: algorithms and applications*. Springer Nature, 2022.
- [12] Pedro Domingos. *The master algorithm: How the quest for the ultimate learning machine will remake our world*. Basic Books, 2015.
- [13] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016. <http://www.deeplearningbook.org>.
- [14] Yuhao Bai, Baohua Zhang, Naimin Xu, Jun Zhou, Jiayou Shi, and Zhihua Diao. Vision-based navigation and guidance for agricultural autonomous vehicles and robots: A review. *Computers and Electronics in Agriculture*, 205:107584, 2023.
- [15] Amin Ghobadpour, German Monsalve, Alben Cardenas, and Hossein Mousazadeh. Off-road electric vehicles and autonomous robots in agricultural sector: trends, challenges, and opportunities. *Vehicles*, 4(3):843–864, 2022.
- [16] Valda Rondelli, Bruno Franceschetti, and Dario Mengoli. A review of current and historical research contributions to the development of ground autonomous vehicles for agriculture. *Sustainability*, 14(15):9221, 2022.
- [17] Jinlin Xue, Lei Zhang, and Tony E Grift. Variable field-of-view machine vision based row guidance of an agricultural robot. *Computers and Electronics in Agriculture*, 84:85–91, 2012.
- [18] Peidong Wang, Zhijun Meng, Changhai Luo, and Hebo Mei. Path recognition for agricultural robot vision navigation under weed environment. In *Computer and Computing Technologies in Agriculture VII: 7th IFIP WG 5.14 International Conference, CCTA 2013, Beijing, China, September 18–20, 2013, Revised Selected Papers, Part I 7*, pages 242–248. Springer, 2014.
- [19] Paul VC Hough. Method and means for recognizing complex patterns, December 18 1962. US Patent 3,069,654.
- [20] Andrew English, Patrick Ross, David Ball, and Peter Corke. Vision based guidance for robot navigation in agriculture. In *2014 IEEE International Conference on Robotics and Automation (ICRA)*, pages 1693–1698. IEEE, 2014.
- [21] OpenCV. OpenCV, 2021. Computer software.
- [22] Luis Emmi, Mariano Gonzalez-de Soto, Gonzalo Pajares, and Pablo Gonzalez-de Santos. Integrating sensory/actuation systems in agricultural vehicles. *Sensors*, 14(3):4014–4049, 2014.
- [23] Guoquan Jiang, Zhiheng Wang, and Hongmin Liu. Automatic detection of crop rows based on multi-rows. *Expert systems with applications*, 42(5):2429–2441, 2015.
- [24] Hamed Ramezani, Hassan ZakiDizaji, Hassan Masoudi, and Gholamreza Akbarizadeh. A new dsmts algorithm for real-time pedestrian detection in autonomous agricultural tractors as a computer vision system. *Measurement*, 93:126–134, 2016.

- [25] Yerania Campos, Humberto Sossa, and Gonzalo Pajares. Spatio-temporal analysis for obstacle detection in agricultural videos. *Applied Soft Computing*, 45:86–97, 2016.
- [26] Palepu V Santhi, Nellore Kapileswar, Vijay KR Chenchela, and CH Venkata Siva Prasad. Sensor and vision based autonomous agribot for sowing seeds. In *2017 International Conference on Energy, Communication, Data Analytics and Soft Computing (ICECDS)*, pages 242–245. IEEE, 2017.
- [27] MathWorks. Matlab, 2021. Computer software.
- [28] Josiah Radcliffe, Julie Cox, and Duke M Bulanon. Machine vision for orchard navigation. *Computers in Industry*, 98:165–171, 2018.
- [29] National Instruments. Labview. Austin, TX: National Instruments, 2019. Computer software.
- [30] Shuo Zhang, Yunyi Wang, Zhongxiang Zhu, Zhen Li, Yuefeng Du, and Enrong Mao. Tractor path tracking control based on binocular vision. *Information Processing in Agriculture*, 5(4):422–432, 2018.
- [31] Federico Pallottino, Paolo Menesatti, Simone Figorilli, Francesca Antonucci, Roberto Tomasone, Andrea Colantoni, and Corrado Costa. Machine vision retrofit system for mechanical weed control in precision agriculture applications. *Sustainability*, 10(7):2209, 2018.
- [32] Yu Fei, Xiang Liu, Qichun Zhao, Ying Zhuang, Gonglei Liao, and Qiang Fu. Obstacle detection for agricultural machinery vehicle. In *Proceedings of the 2019 International Conference on Artificial Intelligence and Computer Science*, pages 126–131, 2019.
- [33] Samuel J LeVoor, Peter A Farley, Tao Sun, and Chong Xu. High-accuracy adaptive low-cost location sensing subsystems for autonomous rover in precision agriculture. *IEEE Open Journal of Industry Applications*, 1:74–94, 2020.
- [34] Wei Zhao, Xuan Wang, Bozhao Qi, and Troy Runge. Ground-level mapping and navigating for agriculture based on iot and computer vision. *IEEE Access*, 8:221975–221985, 2020.
- [35] SP Orlov, SV Susarev, and AS Morev. Machine vision system for autonomous agricultural vehicle. In *2020 International Conference on Industrial Engineering, Applications and Manufacturing (ICIEAM)*, pages 1–5. IEEE, 2020.
- [36] Samwel Opiyo, Cedric Okinda, Jun Zhou, Emmy Mwangi, and Nelson Makange. Medial axis-based machine-vision system for orchard robot navigation. *Computers and Electronics in Agriculture*, 185:106153, 2021.
- [37] Jingyao Gai, Lirong Xiang, and Lie Tang. Using a depth camera for crop row detection and mapping for under-canopy navigation of agricultural robotic vehicle. *Computers and Electronics in Agriculture*, 188:106301, 2021.
- [38] Giulio Reina and Annalisa Milella. Towards autonomous agriculture: Automatic ground detection using trinocular stereovision. *Sensors*, 12(9):12405–12423, 2012.
- [39] Patrick Ross, Andrew English, David Ball, Ben Upcroft, Gordon Wyeth, and Peter Corke. Novelty-based visual obstacle detection in agriculture. In *2014 IEEE International Conference on Robotics and Automation (ICRA)*, pages 1699–1705. IEEE, 2014.
- [40] Sebastian Haug, Andreas Michaels, Peter Biber, and Jörn Ostermann. Plant classification system for crop/weed discrimination without segmentation. In *IEEE winter conference on applications of computer vision*, pages 1142–1149. IEEE, 2014.
- [41] Leo Breiman. Random forests. *Machine learning*, 45:5–32, 2001.
- [42] Anil K Jain and Stan Z Li. *Handbook of face recognition*, volume 1. Springer, 2011.
- [43] Andrew English, Patrick Ross, David Ball, Ben Upcroft, and Peter Corke. Learning crop models for vision-based guidance of agricultural robots. In *2015 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 1158–1163. IEEE, 2015.
- [44] Corinna Cortes and Vladimir Vapnik. Support vector machine. *Machine learning*, 20(3):273–297, 1995.
- [45] Fangwen Shu, Paul Lesur, Yaxu Xie, Alain Pagani, and Didier Stricker. Slam in the field: An evaluation of monocular mapping and localization on challenging dynamic agricultural environment. In *Proceedings of the IEEE/CVF winter conference on applications of computer vision*, pages 1761–1771, 2021.
- [46] Edmund J Sadgrove, Greg Falzon, David Miron, and David W Lamb. Real-time object detection in agricultural/remote environments using the multiple-expert colour feature extreme learning machine (mec-elm). *Computers in Industry*, 98:183–191, 2018.
- [47] Kim Arild Steen, Peter Christiansen, Henrik Karstoft, and Rasmus Nyholm Jørgensen. Using deep learning to challenge safety standard for highly autonomous machines in agriculture. *Journal of Imaging*, 2(1):6, 2016.
- [48] Peter Christiansen, Lars N Nielsen, Kim A Steen, Rasmus N Jørgensen, and Henrik Karstoft. Deepanomaly: Combining background subtraction and deep learning for detecting obstacles and anomalies in an agricultural field. *Sensors*, 16(11):1904, 2016.
- [49] Hanwen Kang and Chao Chen. Fruit detection and segmentation for apple harvesting using visual sensor in orchards. *Sensors*, 19(20):4599, 2019.
- [50] Luis Barba-Guaman, Jose Eugenio Naranjo, and Anthony Ortiz. Deep learning framework for vehicle and pedestrian detection in rural roads on an embedded gpu. *Electronics*, 9(4):589, 2020.
- [51] Esma Mujkic, Dan Hermann, Ole Ravn, Morten L Bilde, and Nils A Andersen. Towards semantic scene segmentation for autonomous agricultural vehicles. In *2020 16th International Conference on Control, Automation, Robotics and Vision (ICARCV)*, pages 990–995. IEEE, 2020.
- [52] Hanwen Kang, Hongyu Zhou, Xing Wang, and Chao Chen. Real-time fruit recognition and grasping estimation for robotic apple harvesting. *Sensors*, 20(19):5670, 2020.
- [53] Charles R Qi, Hao Su, Kaichun Mo, and Leonidas J Guibas. Pointnet: Deep learning on point sets for 3d classification and segmentation. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 652–660, 2017.
- [54] Jing Li, Jialin Yin, and Lin Deng. A robot vision navigation method using deep learning in edge computing environment. *EURASIP Journal on Advances in Signal Processing*, 2021:1–20, 2021.
- [55] Magda Skoczko, Marcin Ochman, Krystian Spyra, Maciej Nikodem, Damian Krata, Marcin Panek, and Andrzej Pawłowski. Obstacle detection system for agricultural mobile robot application using rgb-d cameras. *Sensors*, 21(16):5292, 2021.
- [56] Eleni Vrochidou, Konstantinos Tziridis, Alexandros Nikolaou, Theofanis Kalampokas, George A Papakostas, Theodore P Pachidis, Spyridon Mamalis, Stefanos Koundouras, and Vassilis G Kaburlasos. An autonomous grape-harvester robot: integrated system architecture. *Electronics*, 10(9):1056, 2021.
- [57] Morgan Quigley, Ken Conley, Brian Gerkey, Josh Faust, Tully Foote, Jeremy Leibs, Rob Wheeler, and Andrew Ng. ROS: an open-source robot operating system. *IEEE Robotics & Automation Magazine*, 15(3):72–82, 2009.
- [58] Enrico Bellocchio, Francesco Crocetti, Gabriele Costante, Mario Luca Fravolini, and Paolo Valigi. A novel vision-based weakly supervised framework for autonomous yield estimation in agricultural applications. *Engineering Applications of Artificial Intelligence*, 109:104615, 2022.
- [59] Raphaël d’Andrimont, Momchil Yordanov, Laura Martinez-Sanchez, and Marijn Van der Velde. Monitoring crop phenology with street-level imagery using computer vision. *Computers and Electronics in Agriculture*, 196:106866, 2022.
- [60] Esma Mujkic, Mark P Philipsen, Thomas B Moeslund, Martin P Christiansen, and Ole Ravn. Anomaly detection for agricultural vehicles using autoencoders. *Sensors*, 22(10):3608, 2022.
- [61] Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. Imagenet: A large-scale hierarchical image database. *IEEE Conference on Computer Vision and Pattern Recognition*, pages 248–255, 2009.
- [62] Mark Everingham, Luc Van Gool, Christopher KI Williams, John Winn, and Andrew Zisserman. The pascal visual object classes (voc) challenge. *International Journal of Computer Vision*, 88(2):303–338, 2010.
- [63] Tsung-Yi Lin, Michael Maire, Serge Belongie, James Hays, Pietro Perona, Deva Ramanan, Piotr Dollár, and C Lawrence Zitnick. Microsoft coco: Common objects in context. In *European conference on computer vision*, pages 740–755. Springer, 2014.